

Aprendizado de Máquina e Ciência de Dados

Predição de Aprovação de Acesso a Recursos

Adriana Melcop
Centro de Informática - UFPE
Recife, Brasil
atmc@cin.ufpe.br

Marcela Raposo
Centro de Informática - UFPE
Recife, Brasil
mpr@cin.ufpe.br

Thawan Ribeiro
Centro de Informática - UFPE
Recife, Brasil
trs3@cin.ufpe.br

Resumo—Este trabalho desenvolve e avalia modelos de classificação binária para prever a aprovação de solicitações de acesso a recursos, usando a base Amazon.com Employee Access Challenge. O problema é relevante porque decisões incorretas em controle de acesso podem gerar riscos de segurança, quando um acesso indevido é concedido, ou prejuízos operacionais, quando um acesso legítimo é negado. O conjunto contém 32.769 solicitações, 9 atributos categóricos originais e forte desbalanceamento entre as classes: 94,21% de acessos concedidos e 5,79% de acessos negados. Foram realizadas análise exploratória, tratamento defensivo de dados faltantes, agrupamento de categorias raras, engenharia de atributos, divisão estratificada em treino, validação e teste, comparação com e sem Random Undersampling e tunagem de hiperparâmetros. Os modelos avaliados foram Regressão Logística, Random Forest, Extra Trees e Bernoulli Naive Bayes, além de um Dummy Classifier como baseline. A melhor configuração foi Extra Trees sem reamostragem, com threshold 0,55, obtendo no teste acurácia de 0,9412, AUC-ROC de 0,8189, F_1 macro de 0,7071 e F_1 da classe negada de 0,4453.

I. INTRODUÇÃO

Sistemas de controle de acesso são usados para decidir se uma pessoa, aplicação ou processo deve receber permissão para acessar determinado recurso. Em ambientes corporativos, essa decisão aparece em solicitações de acesso a sistemas internos, bases de dados, ferramentas administrativas, documentos e serviços de infraestrutura. O erro nesse processo possui impacto prático direto: conceder acesso a quem deveria ser bloqueado pode criar vulnerabilidades de segurança, enquanto negar acesso a quem deveria ser autorizado pode atrasar atividades legítimas e gerar retrabalho para equipes de suporte.

O tema do projeto é a predição de aprovação de acesso a recursos, formulada como um problema de classificação binária supervisionada. A variável alvo é ACTION, em que ACTION = 1 representa acesso concedido e ACTION = 0 representa acesso negado. O objetivo principal é construir um classificador capaz de distinguir os dois resultados, prestando atenção especial à classe minoritária, que corresponde às solicitações negadas.

A principal dificuldade do problema é o desbalanceamento. Como a maioria das solicitações da base é concedida, um classificador que sempre prevê acesso concedido pode alcançar acurácia elevada, mas falhar exatamente no ponto mais importante para segurança: identificar solicitações que deveriam ser negadas. Por isso, a avaliação não se limita à acurácia; são

usadas também precisão, recall, F_1 , AUC-ROC, PR-AUC da classe 0 e métricas derivadas da matriz de confusão.

As principais contribuições do trabalho são: (i) análise exploratória dos dados categóricos e desbalanceados; (ii) pré-processamento adequado para identificadores categóricos de alta cardinalidade; (iii) comparação entre modelos com e sem reamostragem; (iv) tunagem de hiperparâmetros e threshold em validação; e (v) avaliação final em teste reservado. Dessa forma, o projeto busca não apenas obter bom desempenho médio, mas também discutir o comportamento do modelo em um contexto no qual os erros possuem custos diferentes.




Figura 1. Distribuição das classes da variável ACTION.

II. ANÁLISE DE DADOS E FEATURE ENGINEERING

A. Descrição do conjunto de dados

Foi utilizada a base Amazon.com Employee Access Challenge, disponibilizada no Kaggle. Cada linha representa uma solicitação de acesso. O dataset possui 32.769 amostras e 10 colunas: a variável alvo ACTION e 9 atributos explicativos. Embora os atributos sejam representados por números inteiros, eles são identificadores categóricos, não grandezas contínuas. Portanto, valores como RESOURCE = 1000 e RESOURCE = 1001 não devem ser interpretados como próximos ou ordenáveis.

A Tabela I mostra que a base possui alta cardinalidade, principalmente em RESOURCE, MGR_ID e

Tabela I
RESUMO ESTRUTURAL DAS VARIÁVEIS EXPLICATIVAS.

Atributo	Valores únicos	% únicos
RESOURCE	7518	22,94
MGR_ID	4243	12,95
ROLE_FAMILY_DESC	2358	7,20
ROLE_DEPTNAME	449	1,37
ROLE_TITLE	343	1,05
ROLE_CODE	343	1,05
ROLE_ROLLUP_2	177	0,54
ROLE_ROLLUP_1	128	0,39
ROLE_FAMILY	67	0,20

ROLE_FAMILY_DESC. Esse aspecto influencia diretamente a escolha do pré-processamento, pois uma codificação ingênua poderia gerar dimensionalidade muito alta e baixa generalização para categorias raras. Além disso, como muitos valores aparecem poucas vezes, o modelo precisa lidar com combinações pouco observadas de gerente, recurso e cargo.




Figura 2. Cardinalidade dos atributos explicativos da base.

B. Análise exploratória

A análise inicial verificou tipos de dados, valores únicos, dados faltantes, duplicatas, distribuição da variável alvo, categorias raras e associações entre atributos e alvo. Todas as colunas estavam no tipo inteiro e não houve valores faltantes nem linhas duplicadas no carregamento analisado. Mesmo assim, como os atributos são categóricos, o pipeline manteve uma etapa de imputação com o token `__MISSING__`, de forma defensiva, para lidar com eventuais ausências em novos dados sem criar valores numéricos artificiais.

A distribuição da variável alvo evidenciou o desbalanceamento: 30.872 amostras pertencem à classe 1, ou 94,21%, enquanto apenas 1.897 amostras pertencem à classe 0, ou 5,79%. Esse resultado é central para a interpretação do projeto, pois a classe 0 é justamente a mais crítica do ponto de vista de segurança: ela representa solicitações que deveriam ser negadas. Portanto, a simples maximização da acurácia poderia produzir um modelo pouco útil na prática.

A análise de outliers precisou ser adaptada à natureza dos dados. Como as variáveis são identificadores categóricos, box-plots e intervalo interquartil não são interpretáveis: um código alto não significa um valor extremo. Assim, o comportamento mais próximo de outlier foi tratado como categoria rara. Em RESOURCE, 93,23% das categorias aparecem menos de 10

	coluna	tipo	valores_unicos	faltantes	percentual_faltantes
0	ACTION	int64	2	0	0.0
1	RESOURCE	int64	7518	0	0.0
2	MGR_ID	int64	4243	0	0.0
3	ROLE_ROLLUP_1	int64	128	0	0.0
4	ROLE_ROLLUP_2	int64	177	0	0.0
5	ROLE_DEPTNAME	int64	449	0	0.0
6	ROLE_TITLE	int64	343	0	0.0
7	ROLE_FAMILY_DESC	int64	2358	0	0.0
8	ROLE_FAMILY	int64	67	0	0.0
9	ROLE_CODE	int64	343	0	0.0

Quantidade de linhas duplicadas: 0

Figura 3. Verificação inicial de qualidade dos dados no notebook.

vezes e correspondem a 45,17% das linhas; em MGR_ID, 74,92% das categorias são raras e concentram 33,30% das linhas. Por isso, o codificador foi configurado para agrupar categorias infrequentes.

	feature	categorias_total	categorias_com_menos_de_10_ocorrencias	percentual_categorias_raras	linhas_em_categorias_raras	percentual_linhas_raras
0	RESOURCE	7518	7009	93.23	14801	45.17
1	MGR_ID	4243	3179	74.92	10913	33.30
6	ROLE_FAMILY_DESC	2358	1889	80.11	5790	17.67
5	ROLE_TITLE	343	129	37.61	510	1.56
8	ROLE_CODE	343	129	37.61	510	1.56
4	ROLE_DEPTNAME	449	120	26.73	480	1.46
3	ROLE_ROLLUP_2	177	43	24.29	157	0.48
2	ROLE_ROLLUP_1	128	23	17.97	75	0.23
7	ROLE_FAMILY	67	17	25.37	75	0.23

Figura 4. Presença de categorias raras nas variáveis de alta cardinalidade.

Para avaliar associação entre atributos categóricos e a variável alvo foi usado Cramér's V. Os maiores valores foram observados em MGR_ID (0,4540), RESOURCE (0,3065), ROLE_FAMILY_DESC (0,2986) e ROLE_DEPTNAME (0,2642). Isso sugere que informações sobre gerente, recurso solicitado e estrutura de cargo/departamento são importantes para prever a decisão de acesso. O resultado também indica que os atributos não têm todos a mesma relevância: alguns identificadores carregam mais informação sobre o padrão de aprovação do que outros.




Figura 5. Associação entre atributos categóricos e a variável alvo por Cramér's V.

Além da associação de cada atributo com a variável alvo, também foi analisada a relação entre os próprios atributos categóricos por meio da Informação Mútua Normalizada.

Essa análise ajuda a identificar possíveis redundâncias entre variáveis, especialmente em atributos hierárquicos ou semanticamente próximos, como `ROLE_TITLE` e `ROLE_CODE`.




Figura 6. Associação entre atributos categóricos por Informação Mútua Normalizada.

C. Pré-processamento dos dados

O pré-processamento foi definido considerando que todos os atributos explicativos são categóricos. O pipeline contém: (i) imputação constante com `__MISSING__`; (ii) codificação one-hot; e (iii) agrupamento automático de categorias raras por meio do parâmetro `min_frequency=10`. Essa escolha evita tratar os IDs como números contínuos e reduz o impacto de categorias pouco frequentes.

Não foi aplicado *feature scaling*, pois o conjunto final de entrada é uma matriz esparsa binária produzida pelo `OneHotEncoder`. Normalizações como `StandardScaler` ou `MinMaxScaler` não são necessárias para os modelos de árvore e não têm interpretação direta para variáveis indicadoras categóricas. No caso da Regressão Logística, a representação one-hot já coloca as variáveis na mesma escala binária.

Outro cuidado importante foi ajustar o pré-processador apenas sobre o conjunto de treino. Essa decisão impede vazamento de informação, pois categorias presentes apenas na validação ou no teste não influenciam a construção do espaço de features. Esse procedimento torna a avaliação mais fiel ao cenário real, no qual novas solicitações podem conter combinações ainda não vistas durante o treinamento.

D. Divisão dos dados

Os dados foram divididos em treino, validação e teste com estratificação pela variável alvo. A estratificação preserva a proporção das classes em todos os subconjuntos, o que é importante em cenários desbalanceados. O conjunto de validação foi usado para comparar modelos, escolher hiperparâmetros e selecionar `threshold`; o conjunto de teste ficou reservado para a avaliação final.

Tabela II
DIVISÃO ESTRATIFICADA DOS DADOS.

Conjunto	Amostras	Classe 0	Classe 1
Treino	22.938	5,79%	94,21%
Validação	4.915	5,78%	94,22%
Teste	4.916	5,80%	94,20%

E. Feature engineering

Foram criadas duas interações categóricas: `ROLE_FAMILY__ROLE_TITLE`, que combina família e título do cargo, e `RESOURCE__ROLE_CODE`, que combina o recurso solicitado com o código do papel. A motivação é representar padrões do tipo “determinado recurso costuma ser apropriado para determinado papel”. Como essas variáveis são construídas apenas a partir de atributos de entrada, sem usar `ACTION`, elas não causam vazamento da variável alvo.

Após a engenharia de atributos, o número de features categóricas passou de 9 para 11. Depois da imputação, one-hot encoding e agrupamento de categorias raras, a matriz final ficou com 2.658 colunas codificadas. Essa dimensionalidade é esperada em dados categóricos de alta cardinalidade e justifica o uso de modelos capazes de trabalhar com matrizes esparsas.

F. Reamostragem

Para atender ao requisito de comparação com e sem balanceamento, foi aplicado `Random Undersampling` parcial somente no conjunto de treino. `SMOTE` não foi escolhido como técnica principal porque a interpolação de IDs categóricos poderia criar combinações sem significado real. O `undersampling` reduziu a predominância da classe majoritária sem alterar validação e teste, que permaneceram com a distribuição original do problema.

Tabela III
DISTRIBUIÇÃO DAS CLASSES ANTES E DEPOIS DO UNDERSAMPLING NO TREINO.

Cenário	Classe	Qtd.	%
Treino original	0	1.328	5,79
Treino original	1	21.610	94,21
Treino com undersampling	0	1.328	28,57
Treino com undersampling	1	3.320	71,43

III. MODELAGEM

Foram avaliados quatro modelos reais e um baseline. O `Dummy Classifier` prevê sempre a classe mais frequente e serve para demonstrar que acurácia alta, sozinha, é insuficiente. A Regressão Logística foi escolhida por ser um modelo linear interpretável e adequado a matrizes esparsas de alta dimensionalidade. O `Random Forest` foi usado por capturar relações não lineares entre recurso, gerente, cargo e departamento. O `Extra Trees` foi incluído como variação de ensemble de árvores com maior aleatoriedade, frequentemente útil em dados tabulares. O `Bernoulli Naive Bayes` foi utilizado por ser simples, rápido e apropriado para entradas binárias esparsas geradas por one-hot encoding.

A tunagem foi realizada por busca em grade no conjunto de validação. Para Regressão Logística foram testados C em $\{0,01,0,05,0,1,1,5,10\}$, penalizações $l1$ e $l2$, e $class_weight$ com e sem `balanced`. Para Random Forest e Extra Trees foram testados $n_estimators$ em $\{100,200\}$, max_depth em $\{None,10,20,40\}$, $min_samples_leaf$ em $\{1,3\}$ e $max_features=sqrt$. Para Bernoulli Naive Bayes foram testados $alpha$ em $\{0,01,0,1,0,5,1,2\}$ e fit_prior verdadeiro ou falso.

Além dos hiperparâmetros, foram avaliados thresholds de 0,30 a 0,95, com passo 0,05. A seleção final priorizou o F_1 da classe 0, pois essa classe representa acessos negados e é minoritária. Entretanto, para evitar um modelo excessivamente restritivo, foram preferidas configurações com $recall_1$ maior ou igual a 0,85. Esse critério explicita o trade-off do problema: reduzir concessões indevidas é importante, mas negar uma quantidade muito alta de acessos legítimos também é prejudicial para a operação.




Figura 7. Comparação dos modelos e cenários de reamostragem na validação.

IV. ANÁLISE E COMPARAÇÃO DE RESULTADOS

As métricas utilizadas foram acurácia, precisão, recall, F_1 da classe 0, F_1 macro, AUC-ROC, PR-AUC da classe 0, taxa de concessão indevida e taxa de negação indevida. A taxa de concessão indevida foi calculada como:

$$TCI = \frac{FP}{TN + FP}, \quad (1)$$

em que FP representa solicitações realmente negadas, mas previstas como concedidas. Essa métrica é relevante porque indica o percentual de acessos indevidamente liberados entre os casos que deveriam ser bloqueados. Já a taxa de negação indevida representa solicitações realmente concedidas, mas previstas como negadas, sendo importante para avaliar o impacto operacional do modelo.

A Tabela IV mostra que o Dummy atinge acurácia de 0,9422, mas possui F_1 da classe 0 igual a zero, confirmando que acurácia isolada é enganosa. Os melhores resultados foram obtidos por Extra Trees e Random Forest sem reamostragem. A aplicação de undersampling aumentou o recall da classe 0 em alguns casos, mas reduziu acurácia e F_1 macro, indicando um trade-off entre bloquear mais acessos negados e não prejudicar demais acessos legítimos.




Figura 8. Comparação do F_1 da classe 0 após tunagem de hiperparâmetros e threshold.




Figura 9. Taxa de concessão indevida após tunagem de hiperparâmetros e threshold.

A configuração escolhida foi Extra Trees sem reamostragem, com $n_estimators=200$, $max_depth=None$, $min_samples_leaf=1$, $max_features=sqrt$ e threshold 0,55. Na validação, essa configuração obteve F_1 da classe 0 igual a 0,5047, F_1 macro de 0,7383, AUC-ROC de 0,8357 e taxa de concessão indevida de 0,5317.




Figura 10. Trade-off de threshold do modelo Extra Trees na validação.

A análise de threshold mostrou que aumentar o limiar torna o modelo mais conservador: a taxa de concessão indevida diminui, mas o recall da classe 1 também cai, ou seja, mais acessos legítimos passam a ser negados. O threshold 0,55 foi escolhido porque apresentou o maior F_1 da classe 0 entre as configurações que preservavam $recall_1$ acima de 0,85.

Tabela IV
MELHOR CONFIGURAÇÃO DE CADA MODELO/CENÁRIO NA VALIDAÇÃO APÓS AJUSTE DE HIPERPARÂMETROS E THRESHOLD.

Modelo	Reamostragem	Th.	Acc.	Prec.0	Rec.0	F_1 0	F_1 macro	TCI
Extra Trees	Sem	0,55	0,9469	0,5473	0,4683	0,5047	0,7383	0,5317
Random Forest	Sem	0,60	0,9465	0,5425	0,4718	0,5047	0,7382	0,5282
Random Forest	Com under.	0,30	0,9347	0,4385	0,4648	0,4513	0,7083	0,5352
Extra Trees	Com under.	0,40	0,9111	0,3461	0,6056	0,4405	0,6961	0,3944
Reg. Logística	Sem	0,70	0,9353	0,4397	0,4366	0,4382	0,7019	0,5634
Reg. Logística	Com under.	0,45	0,9080	0,3091	0,4789	0,3757	0,6630	0,5211
Bernoulli NB	Sem	0,65	0,8655	0,2326	0,5775	0,3316	0,6284	0,4225
Bernoulli NB	Com under.	0,30	0,8383	0,2073	0,6373	0,3129	0,6106	0,3627
Dummy	Sem	0,30	0,9422	0,0000	0,0000	0,0000	0,4851	1,0000

A. Avaliação final no teste

Após escolher modelo, hiperparâmetros e threshold usando apenas a validação, a avaliação final foi realizada no teste. A Tabela V compara o threshold padrão 0,50 com o threshold escolhido 0,55.

Tabela V
RESULTADO FINAL NO CONJUNTO DE TESTE.

Avaliação	Acc.	Prec.0	Rec.0	F_1 0	F_1 macro	TCI
Th. 0,50	0,9447	0,5367	0,3333	0,4113	0,6911	0,6667
Th. 0,55	0,9412	0,4915	0,4070	0,4453	0,7071	0,5930

Com threshold 0,55, a acurácia caiu levemente de 0,9447 para 0,9412, mas o F_1 da classe 0 aumentou de 0,4113 para 0,4453, e o F_1 macro subiu de 0,6911 para 0,7071. A taxa de concessão indevida caiu de 0,6667 para 0,5930, indicando melhor controle sobre a classe crítica. A matriz de confusão final foi: 116 acessos negados corretamente, 169 concessões indevidas, 120 negações indevidas e 4511 acessos concedidos corretamente. A AUC-ROC final foi 0,8189 e a PR-AUC da classe 0 foi 0,3550.




Figura 11. Matriz de confusão do modelo final no conjunto de teste.

Do ponto de vista prático, o modelo final ainda deixa passar parte das solicitações que deveriam ser negadas, mas

melhora o comportamento em relação ao threshold padrão. Essa melhora é importante porque, em controle de acesso, a classe minoritária concentra eventos de maior risco. Ao mesmo tempo, o resultado não elimina a necessidade de revisão humana ou regras complementares para casos críticos, especialmente quando a decisão envolve recursos sensíveis.

A interpretação por importância de atributos indicou que categorias infrequentes de RESOURCE, ROLE_FAMILY_DESC e MGR_ID tiveram grande peso no Extra Trees. Isso é coerente com a EDA: a base possui muitas categorias raras e a decisão de acesso depende fortemente da combinação entre recurso, papel e gerente. Portanto, o desempenho do modelo parece estar associado à capacidade de capturar padrões específicos de contexto organizacional.

V. CONCLUSÃO E DISCUSSÃO

O projeto confirmou que a predição de aprovação de acesso é um problema sensível ao desbalanceamento. A classe majoritária domina a base, tornando a acurácia uma métrica insuficiente. O baseline Dummy apresentou acurácia alta, mas F_1 da classe 0 igual a zero, mostrando que bons resultados aparentes podem mascarar falhas graves na identificação de acessos negados.

A melhor configuração foi Extra Trees sem reamostragem e threshold 0,55. O resultado final melhorou o F_1 da classe 0 e reduziu a taxa de concessão indevida em comparação ao threshold padrão, com pequena perda de acurácia. Isso mostra que a escolha de threshold é uma etapa importante em problemas de controle de acesso, pois permite ajustar o equilíbrio entre segurança e disponibilidade operacional.

Entre as vantagens da solução estão o uso de um pipeline consistente, a prevenção de vazamento de dados, o tratamento adequado de categorias raras, a comparação com e sem reamostragem e a avaliação por múltiplas métricas. As principais limitações são a alta cardinalidade dos atributos, a falta de informações semânticas sobre os códigos, a ausência de atributos sensíveis para análise de justiça entre grupos e a inexistência de uma matriz de custos real para ponderar concessões indevidas e negações indevidas.

Também é importante destacar que o modelo foi treinado em um recorte específico de dados. Em um ambiente real, padrões de solicitação de acesso podem mudar com reorganizações internas, criação de novos recursos, alterações de cargo, entrada de novos gestores e mudanças nas políticas de segurança.

Assim, seria necessário monitorar degradação de desempenho ao longo do tempo e atualizar o modelo periodicamente.

Como trabalhos futuros, recomenda-se testar CatBoost ou target encoding com validação cruzada, aplicar calibração de probabilidades, usar validação cruzada estratificada, investigar explicabilidade com SHAP e definir, com especialistas de segurança, uma função de custo explícita para falsos positivos e falsos negativos. Também seria interessante avaliar o modelo em dados mais recentes ou em cenários com mudanças organizacionais, pois padrões de acesso podem variar ao longo do tempo.

Do ponto de vista de implantação, a solução não deveria substituir automaticamente políticas de segurança já existentes. Um uso mais adequado seria como ferramenta de apoio à decisão, priorizando solicitações com maior risco para revisão humana ou sinalizando padrões incomuns para auditoria. Dessa forma, o modelo poderia reduzir esforço operacional sem concentrar toda a responsabilidade em uma predição automática.

Outro cuidado relevante é a interpretação dos erros. Uma concessão indevida pode gerar risco de segurança, enquanto uma negação indevida pode causar atraso e frustração para usuários legítimos. Como esses custos não são equivalentes, a escolha do threshold deve depender do contexto de uso. Em um recurso crítico, pode ser aceitável negar mais solicitações legítimas para reduzir concessões indevidas; em um recurso de baixo risco, a prioridade pode ser preservar fluidez operacional.

Por fim, a análise reforça uma lição importante para problemas desbalanceados: o melhor modelo não é necessariamente o que apresenta maior acurácia. A avaliação precisa considerar a classe minoritária, a matriz de confusão, as curvas de desempenho e o custo prático dos erros. No caso estudado, o Extra Trees com threshold ajustado apresentou o melhor equilíbrio entre as métricas analisadas, mas ainda há espaço para melhorias, especialmente na recuperação da classe negada.

REFERÊNCIAS

- [1] Kaggle, “Amazon.com - Employee Access Challenge,” base de dados para classificação de solicitações de acesso. Disponível em: <https://www.kaggle.com/c/amazon-employee-access-challenge>.
- [2] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [3] G. Lemaitre, F. Nogueira, and C. K. Aridas, “Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning,” *Journal of Machine Learning Research*, vol. 18, no. 17, pp. 1–5, 2017.